

执行摘要

本报告提出了一套基于开源大语言模型的“双碳”政策与企业应用智能问答系统设计方案。项目目标包括集成国家级和北京市/地方双碳政策、技术标准和补贴指南，构建自动更新的政策知识库；设计企业私有知识库和安全检索机制，实现基于企业数据的碳排放核算；支持自然语言问答、自动报告生成与润色等功能；并保证低成本部署、高隐私性安全。我们比较了DeepSeek-V3、ChatGLM2-6B、百川13B、通义14B等开源模型（参数规模从6B到670B不等），分析了其许可、性能、微调与量化部署策略，并估算了在RTX4090单/双卡环境下的推理延迟和吞吐^{1 2}。知识库与数据工程方面，列出了国家/地方政府网站、行业标准、企业内部能源及生产数据等多种来源，介绍了数据抽取清洗、结构化、向量化和检索增强生成（RAG）流程，并提出定期自动更新和版本管理策略^{3 4}。在隐私安全方面，设计了企业本地部署架构图，分析了差分隐私和联邦学习的应用前景，提出了访问控制与审计机制，并强调遵守《个人信息保护法》《数据安全法》等合规要点^{5 6}。碳核算方法适合中小企业，推荐了典型核算流程与所需数据字段（如燃料消耗、耗电、物流、差旅等），并使用国家发布的温室气体排放因子计算示例^{3 7}。系统架构采用前端交互、后端API、RAG检索模块和LLM推理引擎相结合的方式（见组件图），支持多角色和多权限管理，并设计了API接口和监控指标。开发计划分为需求、MVP、测试和上线四阶段，并给出人力时间、硬件/云资源预算及风险缓解措施（例如双卡4090方案性价比优于云端A100^{8 9}）。交付物涵盖软件系统、知识库、技术文档和培训材料，验收标准依据功能完备性、性能指标和安全合规性。报告中提供了模型与部署方案对比表格和关键流程的mermaid图，附执行性技术建议，确保方案可实施和高效落地。

1) 项目目标与关键功能

- **知识整合**：收集国家和北京市及地方的“双碳”政策文件（如《碳达峰实施方案》《2030年前碳达峰行动方案》等）以及技术标准（例如GB/T 32150-2015《工业企业温室气体排放核算与报告通则》¹⁰）和各类补贴指南（如北京市光伏补贴政策¹¹）。**实现要点**：建立结构化政策数据库，按主题（能源、工业、交通等）和地域分类存储；使用自然语言处理提取政策要点。**验收标准**：知识库涵盖指定来源的最新文件，并能正确响应对应政策查询（准确率≥90%）。
- **自动更新机制**：定期爬取并更新政策和标准来源网站（如生态环境部、发改委、北京市政府网站等），自动导入新增文件并重新构建索引。**实现要点**：设置网页监控或RSS拉取，自动抽取文本、执行清洗（去噪声、格式化），并增量更新向量检索索引¹²。**验收标准**：系统能在文件发布后24小时内更新知识库，查询结果包含新发布信息。
- **私有知识库设计**：企业内部知识库用于存储私有数据（能源计量、电力账单、设备信息、生产量、出行数据等）。**实现要点**：企业数据与公共知识分离，私有知识库部署于本地（可加密），采用向量数据库（如Milvus）存储文件嵌入。问答时，系统能够检索并综合私有与公共知识。**验收标准**：在问答中正确调用企业数据示例并生成合理答案，且未经授权的外部访问被阻止。
- **安全检索与碳核算**：支持用户输入企业内部原始数据（如单位能耗、生产量），结合政府排放因子库自动计算碳排放量。**实现要点**：内置碳核算公式（排放=活动数据×排放因子），并引用最新版国家温室气体排放因子数据库⁷。同时，检索时对私有数据做脱敏和权限校验。**验收标准**：核算结果符合国家/行业核算指南，与人工计算误差<5%；未经授权用户无法访问或修改计算模块。
- **自然语言问答**：用户可用中文提问，系统使用RAG策略检索相关知识并借助LLM生成答案。**实现要点**：集成问答模块，先对问题做分词、实体识别等预处理，再基于向量检索提取相关文档片段与问题一起输入模型生成回答^{4 13}。**验收标准**：问答正确率达到预期（如政策查询>85%、技术标准查询>80%），且答案引用了可信源。

- **自动报告生成与润色**：根据问答结果或碳核算结果自动生成报告草稿，并用大模型优化文本流畅度。**实现要点**：设计模板和格式（可输出PDF/Word），结合生成模型对表述进行润色。**验收标准**：生成报告逻辑连贯、专业术语正确，人工校对时间显著减少（如节省80%以上）。
- **低成本易部署、高隐私性**：优先采用开源技术和小型号硬件，支持本地化部署。**实现要点**：系统组件采用Docker/容器化；模型可量化以适配RTX4090；数据全程本地化处理（不依赖公网大模型API）。**验收标准**：单机（或小规模集群）环境下能完成全部功能，用户数据不外泄，部署总成本低于预估预算。

2) 技术选型

我们比较了以下开源大模型：

- **DeepSeek-V3.2**：参数规模671亿（MoE结构，每次激活37亿），声称在公开基准上达到“GPT-5”水平，仅略低于Google Gemini 3.0 Pro ¹。许可为完全开源（可在ModelScope/HuggingFace获取），支持研究和商业应用。部署：模型太大需分布式推理，单RTX4090（24GB）需采用4-bit量化，推理性能极低（首token≈12s，后续0.47 token/s）¹⁴；双卡NVLink下4-bit推理可达约1.9 token/s ²。微调：可使用LoRA，但4090单卡显存（21.3GB）只能小批量训练 ¹⁵。**对比**：泛化能力强、支持超长上下文，但对资源要求极高，适合部署资源充足时使用。
- **ChatGLM2-6B**：清华开源中英对话模型，6亿参数。权重对学术研究完全开放，商业使用需官方书面许可 ¹⁶。采用多查询Attention，推理速度提高42% ¹⁷。支持8K上下文（6GB INT4显存）¹⁸。在RTX4090上FP16部署约12GB，可高速推理（数百token/s）。微调：可用LoRA进行领域自定义，且易用主流工具链。**对比**：中文性能优、资源占用低、部署方便，适合实时问答；缺点是参数小，不适合超大任务。
- **百川-13B (Baichuan2-13B)**：百度/清华联合开源，13B参数，使用ALiBi位置编码。许可为开源研究免费，商业使用需联系方式 ¹⁹。提供int8/int4量化权重，可在RTX3090（24GB）上运行且性能基本无损 ²⁰。官方测试显示其吞吐比LLaMA-13B提升31.6% ²¹。RTX4090上FP16权重约27GB，可通过切分或4-bit量化运行（约6GB），推理速度快。微调：可使用QLoRA/LoRA。**对比**：多语言表现强，效率高；缺点显存需求中等，对模型优化有一定要求。
- **通义千问-14B (Qwen-14B)**：阿里巴巴开源，14B参数。通义许可协议：免费商用（用户月活≤1亿无需额外授权 ²²）。中文增强词表，14B版英文理解接近70B模型，数学能力甚至超越GPT-3.5 ²³。FP16权重约28GB，RTX4090上可以加载（需压缩分片）或4-bit量化后（约7GB）。微调：支持LoRA微调。**对比**：中文理解深度高，开源友好；缺点略大、使用需留意许可限制和部署复杂度。

以上模型关键参数、许可和部署策略对比见下表：

模型名称	参数规模	许可类型	微调与量化策略	RTX4090部署方案	优点	缺点
DeepSeek-V3.2	671B (MoE)	完全开源 (HF/MoTa)	支持AWQ/GPTQ4bit, LoRA	单卡24GB需4bit量化（约35GB）， ¹⁴ 双卡NVLink 4bit推理1.9 tok/s ²	泛化能力强、Benchmark领先 ¹	模型过大，单卡难以部署；微调资源消耗巨大

模型名称	参数规模	许可类型	微调与量化策略	RTX4090部署方案	优点	缺点
ChatGLM2-6B	6B	Apache2.0（研究免费，商用需许可） ¹⁶	支持LoRA，原生8K上下文 ¹⁸	FP16约12GB，一卡可运行，推理数百tok/s ¹⁷	中文对话性能优秀，推理快 ¹⁷	参数小，复杂问答和长文档支持有限
百川2-13B	13B	开源社区许可（研究免费，商用申请） ¹⁹	支持Int8/4量化（四卡减小至~6GB） ²⁰	FP16约27GB，可4bit量化；可在一张4090上稳健运行	多语种能力强，推理效率高 ²¹	模型中等大，对显存和优化仍有要求
通义千问-14B	14B	自定义许可（免费商用，超大规模需授权） ²²	支持LoRA微调	FP16约28GB，可4bit量化（约7GB）	中文理解深度高，基础性能强 ²³	模型较大，部署复杂度高

性能估算（RTX4090）：以4位量化推理为例，根据实测，DeepSeek-70B单卡吞吐 ≈ 0.47 tok/s¹⁴，双卡约1.9 tok/s²。13B级模型在4090上推理通常能达到数十tok/s，符合快速响应需求。模型微调时，可采用QLoRA（量化LoRA）进一步降低显存需求。

3) 知识库与数据工程

- 数据源清单：**政府和行业公开信息包括：国家部委网站（生态环境部、发改委、工信部等发布的双碳政策和技术规范）、北京市政府和相关区县网站（地方双碳规划、专项资金、标准指南）、行业标准及指南（如国家发布的排放因子、行业核算指南²⁴）、能源和经济统计数据（国家统计局、能源局数据）、补贴政策（财政部/生态环境部等发布的绿色项目补贴、碳交易支持政策²⁵）。企业内部数据类型包括：能源耗用记录（电力、燃气、水等月度账单）、生产运营数据（产量、原材料用量）、设施设备档案、物流与运输记录（运输量及车型）、员工通勤与出差记录等。
- 数据抽取/清洗/结构化：**对政策文件和标准文本使用爬虫+OCR获取全文，进行去除格式杂质、统一术语等预处理；使用中文分词、命名实体识别标注政策对象、指标等。对表格数据（如排放因子表、补贴表格）进行字段解析，存入数据库。企业结构化数据（数据库/CSV）通过ETL流程清洗空值和异常值后抽取所需字段。所有数据最终以JSON或数据库形式存储，以便查询和检索。
- 分片策略与向量化：**将长文本拆分为较短段落或条目，生成嵌入（Embedding）并存入向量数据库（推荐Milvus/Weaviate/Faiss等）。例如将一份政策文件按自然段分片，每段生成向量并索引。检索时通过相似度匹配找到相关片段。**检索增强生成（RAG）流程：**用户问题转为向量后检索相关文档片段，然后将问题+片段作为提示输入大模型生成答案¹³。
- 自动更新与版本管理：**定期对接官方信息平台（RSS或API），发现新数据后自动触发数据管道。增量更新知识库，并重新计算新文档的嵌入。使用版本控制（如Git或文件哈希）记录知识库更新历史，确保可追溯。设置优先级：例如国家层面文件更新频率高（如国务院批复、部委通知），每日检查；地方性文件每周检查；企业数据定期（每月/每季度）更新。下面表格示例列出部分数据源、更新频率和主要字段：

数据源	类型	更新频率	主要字段示例
国务院/部委网站	政策/规划文件	每日或即时	目标年份、减排目标、行动措施
北京市政府网站	地方政策及专项指南	每周	本市目标、补贴标准、实施细则
国家排放因子数据库 ⁷	排放因子	不定期更新	燃料种类、CO ₂ 排放因子
行业标准数据库	标准/指南	不定期更新	统计口径、核算方法
企业能耗系统	内部数据（能耗、生产）	按月/季度	电量(度)、天然气(立方米)、产量
交通/差旅管理系统	内部数据（出行）	按月	交通工具类型、里程、乘员数

• **RAG检索流程：**用户发起提问→系统通过API接收→预处理（分词、关键词抽取）→在向量库中检索Top-K相关片段→构造Prompt（问题+片段）调用LLM生成答案→后处理（语法校正、格式化）→返回结果。此流程确保答案基于权威文本，减少生成模型凭空“编造”内容 ⁴ ¹³。

4) 隐私与安全

flowchart TD; Data[企业私有数据库] -->|加密访问| API; API --> Auth[身份与权限管理]; Auth --> UI[用户接口]; API -->|安全通道| ModelService[本地LLM服务]; Data --> DP[差分隐私/加密]; ModelService --> Audit[日志审计与监控];

- **企业数据接入架构：**如上架构图所示，采用本地部署模式，企业私有数据存于本地数据库，访问需通过API网关认证授权。所有请求需经过多因素认证和角色权限校验（管理员、审计员、普通用户等）。前端与后端通信使用HTTPS/TLS加密。建议使用基于OAuth2/JWT的机制管理用户权限，并对关键操作（如知识库修改）进行权限限制。
- **差分隐私/联邦学习/本地推理：**企业可在模型微调阶段引入差分隐私技术（对梯度裁剪并加入噪声），保护训练数据 ²⁶ ²⁷。联邦学习可用于跨企业协作情景：各方在本地数据上训练模型，并仅上传加密的模型更新进行联合聚合，无需共享原始数据 ⁵。推荐始终在本地完成模型推理，确保用户输入和企业数据不出本地网络。
- **访问控制与审计：**采用细粒度访问控制，区分数据读写权限。对用户行为进行全程日志记录（包括查询内容、时间、输出结果），便于审计。引入入侵检测（IDS）和终端安全监控，防范恶意爬取。对API调用进行限流保护，防止暴力攻击。定期对生成答案进行合规性审查，如有必要可增加“人工复核”流程。
- **合规要点：**严格遵守《个人信息保护法》《数据安全法》《网络安全法》等国家法律法规 ⁶。进行数据分类分级管理，对个人敏感信息进行脱敏处理。建立数据安全管理制度和应急响应预案。对AI输出内容，参考国家《生成式人工智能服务安全基本要求》中的风险分类，避免生成有害或违规内容。

5) 碳核算方法

针对中小企业特点，建议采用简化但可验证的核算流程：

- 1. 确认边界和范围：**明确核算对象（工厂、园区等），包括Scope 1（直接燃料燃烧、生产过程）和Scope 2（购电购热）排放；可选算Scope 3（物流、差旅）。
- 2. 收集活动数据字段：**包括燃料用量（吨）、电量（kWh）、购入蒸汽/热力（GJ）、原材料用量（吨，如水泥、钢材）、物流运输量（吨公里）、员工通勤方式和里程、出差交通工具与里程、产生废弃物量等³。
- 3. 排放因子应用：**使用国家或行业发布的排放因子。例如，生态环境部新版排放因子数据库⁷提供各类燃料、生产过程的CO₂排放因子。公式示例：`CO2排放 = 活动数据 × 排放因子`。可开发计算示例程序（Python伪代码）：

```
emissions = fuel_tons * co2_factor[fuel_type] + electricity_kwh * co2_factor['electricity']
```

- 4. 结果计算与校验：**计算完成后求和得出总排放量。建议与历史数据或行业平均水平对比，检查数据合理性（如误差应在可接受范围）。对不确定性处理，可对关键因子进行灵敏度分析，或报告置信区间。
- 5. 验证方法：**可以通过第三方核算工具（如GHG Protocol推荐的中国中小企业碳报告工具³）交叉验证结果，或将企业报告与系统计算对比检查。

6) 系统架构与部署

```
graph LR
    subgraph 用户层
        U(用户前端)
    end
    subgraph 后端
        U --> API(API网关)
        API --> Pre(预处理模块)
        Pre --> Store(知识库/向量检索)
        Store --> RAG(RAG检索)
        RAG --> LLM(LLM推理引擎)
        LLM --> Post(答案后处理)
        Post --> API
        API --> Carbon(碳核算服务)
        API --> UI2(前端呈现)
    end
    end
```

- 系统组件：**前端提供交互界面和数据录入；后端API路由至预处理（分词、实体识别），并调用知识检索和LLM推理模块生成答案；同时提供碳核算计算模块。答案生成后通过后处理（语法校正、格式化）输出。数据层包括向量数据库存储政策知识库和企业数据知识库。系统可使用RESTful API设计，关键接口如`/ask`（问答）、`/calc_carbon`（碳核算）、`/generate_report`（报告生成）等，输入输出字段需定义清晰（例如`/ask`输入文本，输出答案和引用片段）。
- 前端与多角色权限：**提供多页面入口：问答页面、碳核算页面、报告查看页面、管理员后台等。权限分为管理员（管理知识库、查看日志、设置模型）、审计员（查看审计日志和报告内容）、普通用户（问答查询、报告生成）。通过登录控制界面和API访问权限。

- **监控与运维指标：**关键指标包括系统响应延迟（SLO可定为95%查询<3秒）、系统吞吐量、LLM推理耗时、检索延迟、错误率、GPU/CPU利用率、内存使用等。业务指标如用户满意度反馈率、答案正确率等应定期评估。可使用Prometheus/Grafana监控，并设定阈值报警（如延迟过高通知运维）。

7) 开发计划与成本估算

- **里程碑：**
 - 需求与方案设计（M0-M1）：明确功能、确定技术选型并搭建基础环境。
 - 原型开发（M2-M4）：实现知识库构建、基础问答流程和碳核算功能（MVP），内部测试并迭代。
 - 测试与优化（M5-M6）：扩大知识库、优化模型效果，完成安全测试和性能调优。
 - 上线部署（M7-M8）：完成部署、用户培训与文档，进入运营维护阶段。
- **人力时间估算：**团队建议5-7人，包括1名项目经理、2名后端开发（含LLM集成和数据工程）、1名前端、1名数据工程师、1名运维/测试。总工时约6-9人月，按阶段分配。
- **硬件/资源预算：**核心硬件为RTX4090显卡。**本地方案：**推荐购置2×RTX4090（24GB NVLink模式）≈¥25,000⁹；服务器（CPU、内存、SSD）≈¥80,000；其他网络存储约¥10,000。合计≈¥115,000。**云方案：**可按需租用GPU实例，例如2×A100（80GB）约¥8,000/月⁹，适合快速扩容测试。

成本对比表：

方案	GPU资源	初期费用	优点	缺点
单卡4090	1×RTX4090	≈ ¥ 13,000	成本低，部署简单；对小模型友好	性能有限，大模型运行困难；吞吐低
双卡4090	2×RTX4090(NVLink)	≈ ¥ 25,000	性能提升显著（推理吞吐3×）；性价比优于单A100 ⁸	硬件成本中等；功耗和冷却需求高
云GPU (2×A100)	2×NVIDIA A100	¥ 8,000/月	算力强可扩展；支持大模型训练与推理	长期成本高；需要公网安全加固

- **风险与缓解：**主要风险有数据质量不足、LLM回答不准确、法规变更频繁等。缓解措施包括：小步迭代开发并频繁验证（用户评测和专家审阅）、构建知识图谱辅助检查、定期更新政策库、对重点输出建立人工审核。

8) 输出物与交付

- **软件系统：**完成后端服务（API、LLM服务、数据库）和前端界面代码，形成可部署软件包。
- **知识库数据：**整理好的政策文档、标准和补贴信息数据库，以及企业示例数据集和排放因子表。
- **技术文档：**需求/设计文档、部署手册、用户手册、API文档等。
- **测试报告：**功能/性能/安全测试结果与修复记录。
- **培训材料：**用户培训和维护培训资料。
- **验收标准：**功能覆盖性（各功能模块完成率100%）、性能指标（SLO达标）、安全合规性（无重大合规问题）、文档完整度。

交付内容将逐项对照以上标准验收，确保系统功能和性能满足要求。

以上方案参考了中文官方资料和开源文档 ¹ ³ ⁵，在满足业务需求的基础上提出了可执行的技术实施方案和优化建议，确保项目可行且高效落地。

¹ DeepSeek V3.2 正式版：强化 Agent 能力，融入思考推理 | DeepSeek API Docs

<https://api-docs.deepseek.com/zh-cn/news/news251201>

² ⁸ ⁹ ¹⁴ ¹⁵ 单双卡RTX 4090挑战DeepSeek70B：本地化大模型部署的硬件极限测试

<https://cloud.baidu.com/article/3734297>

³ Advisory proposal document

https://ghgprotocol.org/sites/default/files/2023-03/Carbon%20Reporting%20Tool%20User%20Guide%20-%20Mandarin_Final%20Mar%202013-print.pdf

⁴ 加快建设全链条、数字化、智能化的全国碳市场管理平台 | 碳市场建设解读^④

https://www.mee.gov.cn/zcwj/zcjd/202509/t20250902_1126715.shtml

⁵ ²⁶ 告别数据泄露：三步构建企业级AI的隐私保护盾 - 文章 - 开发者社区 - 火山引擎

<https://developer.volcengine.com/articles/7600832006402310195>

⁶ 生成式人工智能企业合规及法律尽职调查要点（1）：业务资质和算法模型监管篇 - 专业文章 - 上海 - 上海市锦天城律师事务所

<https://www.allbrightlaw.com/SH/CN/10475/7516036c7af6d283.aspx>

⁷ 国家温室气体排放因子数据库（第二版）正式发布_中华人民共和国生态环境部

https://www.mee.gov.cn/ywgz/ydqhbh/wsqtz/202603/t20260301_1145117.shtml

¹⁰ 国家标准 - 国家标准信息公共服务平台

<https://std.samr.gov.cn/gb/search/gbDetailed?id=71F772D80923D3A7E05397BE0A0AB82A>

¹¹ 精准发力助力“双碳”达标 市级财政将对光伏发电分级分类补贴_部门动态_首都之窗_北京市人民政府门户网站

https://www.beijing.gov.cn/ywdt/gzdt/202305/t20230513_3102806.html

¹² ¹³ 什么是 RAG？ — 检索增强生成 AI 详解 — AWS

<https://aws.amazon.com/cn/what-is/retrieval-augmented-generation/>

¹⁶ ¹⁷ ¹⁸ GitHub - 189569400/ChatGLM2-6B

<https://github.com/189569400/ChatGLM2-6B>

¹⁹ ²⁰ ²¹ baichuan-inc/Baichuan-13B-Base • Hugging Face

<https://huggingface.co/baichuan-inc/Baichuan-13B-Base>

²² LICENSE • Qwen/Qwen-14B at main

<https://huggingface.co/Qwen/Qwen-14B/blob/main/LICENSE>

²³ Qwen-14B 模型详解：参数、评测及开源信息 - 数据学习(DataLearner)

<https://llmlerner.com/ai-models/pretrained-models/Qwen-14B>

²⁴ 关于印发《企业温室气体排放核算与报告指南 发电设施》《企业温室气体排放核查技术指南 发电设施》的通知

https://www.mee.gov.cn/xxgk/xxgk06/202212/t20221221_1008430.html

²⁵ 《碳达峰碳中和“1+N”政策体系已构建 “双碳”工作取得良好开局》-国家发展和改革委员会

https://www.ndrc.gov.cn/fggz/hjzy/tdftzh/202209/t20220923_1336095.html

²⁷ 企业专属AI从0到1：避开隐私雷区，用你的数据安全微调大模型-阿里云开发者社区

<https://developer.aliyun.com/article/1708673>